

Trabalho LEA: Bandits

Inferência após seleção e recompensa acumulada em bandits

Fernanda Borim

RA: 770291

Código: notebook em Python no Google Colab. Repositório GitHub: a inserir.

Este relatório apresenta as respostas das duas partes do trabalho. O objetivo não é apenas executar as simulações, mas interpretar o que cada resultado revela sobre decisões sequenciais. Na Parte 1, o foco está na validade de intervalos de confiança após escolher o braço vencedor. Na Parte 2, o foco está no desempenho de diferentes políticas em termos de recompensa acumulada e no conflito entre maximizar recompensa e estimar todos os parâmetros com precisão.

As simulações foram implementadas em Python. Para manter comparabilidade entre políticas, foi usado o mesmo horizonte nos experimentos principais: $T = 500$. Na Parte 1 foram realizadas 5.000 repetições por política; na Parte 2, 1.000 repetições por política.

1 Parte 1: inferência após seleção

1.1 Resumo do exercício e desenho da simulação

Considere cinco braços, $A = \{1, 2, 3, 4, 5\}$. Quando o braço a é escolhido no instante t , observa-se

$$R_t \mid a_t = a \sim N(\mu_a, 1).$$

Na simulação, o exercício considera o caso nulo:

$$\mu_1 = \mu_2 = \dots = \mu_5 = 0.$$

Ou seja, nenhum braço é realmente melhor que os outros. Se algum braço parecer superior ao final do experimento, isso ocorreu por flutuação amostral ou pelo modo como os dados foram coletados.

Foram comparadas quatro políticas:

- **alocação uniforme aleatória:** escolhe um dos cinco braços com probabilidade $1/5$ em cada rodada;
- **greedy:** escolhe o braço com maior média amostral observada até o momento;
- **UCB:** escolhe o braço com maior escore de média estimada mais bônus de incerteza;
- **Thompson Sampling:** sorteia uma média plausível para cada braço a partir da posteriori e escolhe o maior valor sorteado.

O exercício pede que, ao final de cada experimento, seja calculada a média amostral de cada braço, $\hat{\mu}_a$, e seja selecionado o braço com maior média:

$$\hat{a} = \arg \max_{a \in \{1, \dots, 5\}} \hat{\mu}_a.$$

Em seguida, constrói-se o intervalo usual de 95% para o braço selecionado:

$$\hat{\mu}_{\hat{a}} \pm 1.96 \frac{1}{\sqrt{n_{\hat{a}}}}.$$

Esse intervalo é chamado aqui de *ingênuo*, pois ele trata $\hat{a}$ como se tivesse sido definido antes da coleta dos dados. Na verdade, $\hat{a}$ foi escolhido porque apresentou a maior média observada.

Para implementar Thompson Sampling e uma versão Bayesiana do UCB, foi necessário definir como atualizar a incerteza sobre as médias μ_a . O enunciado fixa a variância observacional como conhecida, $\sigma^2 = 1$, mas não especifica uma priori para μ_a . Por simplicidade, foram usadas priors independentes

$$\mu_a \sim N(0, 1).$$

Essa escolha é apenas operacional, para implementar as políticas adaptativas baseadas em posteriori. A inferência final avaliada pelo exercício continua sendo o intervalo usual solicitado no enunciado.

No UCB foi usado $c = 2$, de modo que o escore de cada braço é dado por

$$\text{escore}_a(t) = m_a(t) + c\sqrt{\log(t+1)}\sqrt{v_a(t)},$$

em que $m_a(t)$ e $v_a(t)$ são a média e a variância posteriores de μ_a . No Thompson Sampling, sorteia-se

$$\tilde{\mu}_a \sim N(m_a(t), v_a(t))$$

para cada braço e escolhe-se aquele com maior valor sorteado. Cada braço recebeu uma observação inicial, para que todas as médias amostrais estivessem definidas.

Além da análise solicitada, foi incluído um controle metodológico: calcular também a cobertura para um braço fixado previamente, o braço 1. Esse controle não substitui a resposta do exercício, mas ajuda a evidenciar que o problema não está na fórmula do intervalo em si. O problema aparece quando o intervalo é aplicado ao braço escolhido por ter apresentado a maior média.

1.2 Cobertura empírica dos intervalos

A Figura 1 compara a cobertura do intervalo aplicado ao braço selecionado com a cobertura do intervalo aplicado ao braço fixado previamente.




Figura 1: Cobertura empírica do intervalo usual. As barras azuis correspondem ao braço selecionado ao final do experimento; as barras laranjas correspondem ao braço 1, fixado antes da observação dos dados.

Tabela 1: Resumo da cobertura e do viés do braço selecionado.

Política	Cobertura selecionado	Cobertura fixo	Média de $\hat{\mu}_a$	$E[n_a]$
Aleatória	0.881	0.951	0.117	99.8
Greedy	0.952	0.961	0.011	470.3
UCB	0.907	0.939	0.082	149.4
Thompson Sampling	0.920	0.929	0.070	185.2

A cobertura empírica não ficou próxima de 95% para todos os procedimentos. O caso mais claro é a alocação uniforme aleatória: quando o intervalo é aplicado ao braço fixo, a cobertura fica em 95,1%, praticamente igual ao valor nominal. Porém, quando o intervalo é aplicado ao braço selecionado, a cobertura cai para 88,1%.

Esse resultado mostra que o problema não decorre apenas da alocação adaptativa. Mesmo quando os braços são amostrados de forma aproximadamente equilibrada, escolher ao final aquele com maior média amostral introduz viés de seleção. O braço vencedor tende a ser aquele que, por acaso, teve uma média mais alta.

UCB e Thompson Sampling também apresentaram cobertura abaixo de 95%, com 90,7% e 92,0%, respectivamente. Nessas políticas, além da seleção final, a própria coleta de dados é adaptativa: braços que parecem melhores ou mais incertos recebem mais observações. Assim, a quantidade de dados por braço depende dos resultados anteriores.

O greedy foi uma exceção aparente, com cobertura próxima da nominal. No entanto, esse resultado precisa ser interpretado com cuidado. No cenário nulo, todos os braços são igualmente bons. Como o greedy tende a concentrar quase todo o experimento em um único braço, a média desse braço passa a ser estimada com grande tamanho amostral e regressa para perto do verdadeiro valor zero. Portanto, a boa cobertura do greedy neste cenário não implica validade geral da inferência após seleção.

1.3 Distribuição do braço vencedor e concentração da alocação

A Figura 2 mostra a média da estimativa do braço selecionado. Como todos os valores verdadeiros são iguais a zero, qualquer deslocamento positivo de $\hat{\mu}_a$ representa viés de seleção.




Figura 2: Média da estimativa do braço selecionado. Como todas as médias verdadeiras são zero, o deslocamento positivo indica viés do vencedor.

A alocação aleatória apresentou o maior viés médio do vencedor, aproximadamente 0,117. Isso ocorre porque, ao final, os cinco braços possuem tamanhos amostrais parecidos; selecionar o maior valor entre cinco médias ruidosas tende a produzir uma estimativa positiva. UCB e Thompson Sampling reduzem parcialmente esse viés, pois alocam mais observações a braços que parecem promissores, reduzindo a variabilidade dessas médias. Ainda assim, a seleção final continua produzindo estimativas otimistas.

A interpretação do greedy fica mais clara quando se analisa a concentração das alocações. A Figura 3 mostra a proporção média destinada ao braço mais alocado em cada experimento, e a Figura 4 ordena os braços dentro de cada simulação, removendo a identidade nominal dos braços.




Figura 3: Proporção média do horizonte destinada ao braço mais alocado. O greedy concentra quase todo o experimento em um único braço.




Figura 4: Alocação média ordenada dentro de cada experimento. A ordenação mostra a concentração real das políticas, sem mascarar o padrão pela simetria entre os cinco braços no caso nulo.

A alocação aleatória distribui as observações de forma relativamente uniforme. Já o greedy coloca, em média, 94,6% do horizonte no braço mais escolhido. UCB e Thompson Sampling ficam em posições intermediárias, com o Thompson Sampling mais concentrado que o UCB neste cenário.

1.4 Respostas da Parte 1

1. A cobertura empírica fica próxima de 95% para todos os procedimentos?

Não. A cobertura empírica não ficou próxima de 95% para todos os procedimentos. Na alocação uniforme aleatória, a cobertura do intervalo aplicado ao braço selecionado foi aproximadamente 88%, bem abaixo da cobertura nominal. Para UCB e Thompson Sampling, a cobertura também ficou abaixo de 95%, embora menos severamente do que na alocação aleatória. O greedy apresentou cobertura próxima de 95%, mas por uma razão específica do caso nulo: a política concentrou quase todas as observações em um único braço, fazendo a média desse braço regressar para zero.

2. Como as diferentes políticas afetam a distribuição de $\hat{\mu}_a$?

Como todas as médias verdadeiras são iguais a zero, uma distribuição de $\hat{\mu}_a$ deslocada para valores positivos é consequência da seleção do máximo. A alocação aleatória apresentou o maior deslocamento positivo, pois escolhe-se o maior valor entre cinco médias com tamanhos amostrais semelhantes. UCB e Thompson Sampling reduziram parcialmente esse viés ao concentrar mais dados em braços promissores, mas ainda apresentaram estimativas vencedoras positivamente enviesadas. O greedy apresentou $\hat{\mu}_a$ mais próximo de zero porque observa quase sempre o mesmo braço.

3. Por que esse fenômeno é relevante em testes A/B, ensaios clínicos adaptativos ou seleção de modelos?

Esse fenômeno é relevante porque, em aplicações reais, é comum testar várias alternativas, escolher a que apresentou melhor desempenho e depois reportar uma estimativa, intervalo de

confiança ou valor-p como se essa alternativa tivesse sido definida antes da coleta dos dados. Em testes A/B, isso pode levar uma empresa a acreditar que uma versão de site ou campanha é superior quando ela apenas teve resultado favorável por acaso. Em ensaios clínicos adaptativos, pode levar à superestimação do efeito de um tratamento. Em seleção de modelos, pode fazer com que o desempenho do modelo escolhido pareça melhor do que realmente é. Possíveis soluções incluem usar uma amostra confirmatória independente, separar seleção e validação, aplicar correções por multiplicidade ou usar métodos de inferência seletiva.

2 Parte 2: recompensa acumulada em um exemplo Poisson

2.1 Resumo do exercício e escolhas de implementação

Na Parte 2, o objetivo muda. Agora queremos comparar políticas em termos de recompensa acumulada. A interpretação é a de um site que, a cada dia, escolhe uma entre cinco campanhas e observa o número de novos cadastros. O modelo é

$$R_t \mid a_t = a \sim \text{Poisson}(\lambda_a),$$

com

$$\lambda = (18, 20, 21, 23, 27).$$

A campanha 5 é a melhor em média, pois possui a maior taxa verdadeira, $\lambda_5 = 27$.

Foram usadas priors independentes

$$\lambda_a \sim \text{Gamma}(\alpha_0, \beta_0),$$

com parametrização por taxa. Adotou-se

$$\alpha_0 = 4, \quad \beta_0 = 0.2.$$

Logo,

$$\mathbb{E}(\lambda_a) = \frac{\alpha_0}{\beta_0} = 20, \quad DP(\lambda_a) = \frac{\sqrt{\alpha_0}}{\beta_0} = 10.$$

Essa priori é centrada em 20 cadastros por dia, valor compatível com a escala das taxas verdadeiras, mas possui desvio-padrão 10, permitindo incerteza relevante antes da coleta dos dados.

Como Poisson e Gamma são conjugadas, após observar soma de recompensas S_a e n_a alocações no braço a ,

$$\lambda_a \mid D_t \sim \text{Gamma}(\alpha_0 + S_a, \beta_0 + n_a).$$

A média posterior é

$$\mathbb{E}(\lambda_a \mid D_t) = \frac{\alpha_0 + S_a}{\beta_0 + n_a}.$$

Foram comparadas cinco políticas: alocação uniforme aleatória, greedy, Thompson Sampling, UCB e epsilon-greedy. No UCB foi usado $c = 2$, mantendo a lógica de bônus de incerteza. No epsilon-greedy foi usado $\epsilon = 0.10$, isto é, 10% das escolhas são aleatórias. No código, a distribuição Gamma foi simulada com a função do NumPy, que usa escala; como a teoria usa taxa, foi usado `scale = 1/beta`.

Também foi calculado o pseudo-arrependimento acumulado. Como a melhor campanha tem taxa 27, o pseudo-arrependimento até T é

$$\sum_{t=1}^T (27 - \lambda_{a_t}).$$

Essa medida usa as taxas verdadeiras da simulação e representa o custo esperado de escolher campanhas subótimas.

2.2 Recompensa acumulada e exploração

A Figura 5 apresenta a trajetória média simulada da recompensa acumulada, junto com a linha do oráculo, que sempre escolheria a campanha 5. A Figura 6 apresenta o pseudo-arrependimento acumulado.




Figura 5: Trajetória média simulada da recompensa acumulada. A linha tracejada representa o oráculo esperado, que sempre escolheria a campanha 5.




Figura 6: Pseudo-arrependimento acumulado. Valores menores indicam menor custo esperado por escolhas subótimas.

A Tabela 2 resume a recompensa acumulada média e o percentual do oráculo.

Tabela 2: Recompensa acumulada média após 500 dias.

Política	Recompensa média	Arrependimento médio	% do oráculo
Thompson Sampling	13,354.9	145.1	98.9%
UCB	13,259.7	240.3	98.2%
Epsilon-greedy	13,063.9	436.1	96.8%
Greedy	12,495.3	1,004.7	92.6%
Aleatória	10,901.4	2,598.6	80.8%

A Figura 7 mostra visualmente essa comparação.




Figura 7: Recompensa média após 500 dias. O oráculo esperado corresponde a $500 \times 27 = 13.500$.

O Thompson Sampling obteve a maior recompensa média, seguido de UCB e epsilon-greedy. As duas primeiras políticas equilibraram bem exploração e aproveitamento, identificando rapidamente a campanha 5 e concentrando nela a maior parte das escolhas. A alocação aleatória teve a menor recompensa, pois distribuiu as decisões quase igualmente entre todas as campanhas, inclusive as piores.

A Figura 8 mostra a alocação média por campanha.




Figura 8: Número médio de dias alocados a cada campanha. Thompson Sampling, UCB e epsilon-greedy concentram a maior parte das decisões na campanha 5.

A alocação aleatória destinou cerca de 100 dias a cada campanha. O Thompson Sampling destinou cerca de 474 dias à campanha 5; o UCB, cerca de 456; e o epsilon-greedy, cerca de 424. Isso explica a diferença de recompensa acumulada entre essas políticas.

2.3 Instabilidade do greedy

O greedy merece análise separada. A política não possui exploração explícita: ela escolhe a campanha com maior média posterior corrente. Quando as primeiras observações favorecem a campanha 5, o greedy pode ser competitivo. Porém, quando uma campanha inferior tem sorte inicial, o greedy pode se prender a ela.

A Figura 9 mostra a probabilidade de cada campanha dominar a alocação do greedy e a recompensa média condicionada a essa campanha dominante.




Figura 9: Instabilidade do greedy. A campanha 5 dominou em apenas 57,6% das simulações; nas demais, o greedy ficou preso em campanhas subótimas.

Na simulação, a campanha 5 foi a mais alocada em 57,6% das repetições. Em 30,8% das repetições, o greedy ficou preso na campanha 4; em 10,6%, na campanha 3; e em 1,0%, na campanha 2. Quando a campanha dominante foi a 5, a recompensa média foi 13.447; quando foi a campanha 4, caiu para 11.475; quando foi a campanha 3, caiu para 10.510; e quando foi a campanha 2, ficou em 10.133.

Portanto, o greedy é competitivo apenas quando acerta cedo. Sua fragilidade está justamente na falta de exploração sistemática para corrigir erros iniciais.

2.4 Recompensa versus estimação dos parâmetros

A política com maior recompensa acumulada não necessariamente estima bem todos os parâmetros λ_a . Esse é um dos principais resultados da Parte 2.

A Figura 10 mostra o erro quadrático médio das estimativas de cada taxa. A Figura 11 resume o compromisso entre recompensa acumulada e erro médio de estimação global.




Figura 10: Erro quadrático médio das estimativas de cada taxa. Valores menores indicam melhor estimação.




Figura 11: Compromisso entre recompensa acumulada e estimação global. A política aleatória estima bem todos os braços, mas acumula pouca recompensa; Thompson Sampling maximiza recompensa, mas sacrifica a precisão nos braços pouco observados.

A alocação aleatória teve a pior recompensa acumulada, mas o menor EQM médio global, 0,2203. Isso ocorre porque ela distribui as observações de forma equilibrada entre as cinco campanhas. O Thompson Sampling teve a melhor recompensa, mas EQM médio global maior, 5,2934. Ele estimou muito bem λ_5 , pois observou a campanha 5 em quase todo o experimento, mas estimou pior as campanhas 1 a 4, que receberam poucas observações. O greedy também teve erro elevado para λ_5 : embora alocue muitos dias à campanha 5 em média, em várias simulações ele quase não a escolhe por ficar preso precocemente em campanhas subótimas. Ao agregar as repetições, essas trajetórias malsucedidas aumentam o erro médio de estimação do braço ótimo.

Assim, há um conflito entre dois objetivos: maximizar recompensa acumulada e estimar todos os braços com precisão. Um bandit voltado à recompensa tende a concentrar observações nos braços promissores; já uma política voltada à estimação precisaria distribuir mais observações entre todos os braços.

2.5 Respostas da Parte 2

1. Quais políticas obtêm maior recompensa acumulada?

A maior recompensa acumulada média foi obtida pelo Thompson Sampling, seguido por UCB, epsilon-greedy, greedy e alocação aleatória. O Thompson Sampling obteve cerca de 98,9% da recompensa esperada do oráculo, e o UCB cerca de 98,2%. A alocação aleatória obteve apenas 80,8% do oráculo, pois não usa as informações coletadas para concentrar decisões na melhor campanha.

2. Quais políticas exploram mais? Quais exploram menos?

A política que mais explora é a alocação aleatória, pois distribui as escolhas quase igualmente entre todas as campanhas. Entre as políticas adaptativas, o epsilon-greedy explora explicitamente com probabilidade $\epsilon = 0.10$; o UCB explora por bônus de incerteza; e o Thompson Sampling explora por amostragem posterior. O greedy é o que menos explora, pois escolhe sempre a campanha com maior média posterior corrente. Porém, essa baixa exploração é arriscada, pois

a política pode se prender a uma campanha subótima.

3. A política greedy é competitiva? Em que situações ela falha?

O greedy pode ser competitivo quando as primeiras recompensas apontam corretamente para a campanha 5. Nesses casos, ele passa a escolher quase sempre a campanha ótima e obtém recompensa próxima à do oráculo. Porém, ele falha quando uma campanha inferior tem sorte inicial ou quando a melhor campanha apresenta valores iniciais baixos. Como não há exploração sistemática, a política pode não corrigir esse erro inicial.

4. A política que maximiza recompensa acumulada também estima bem todos os λ_a ?

Não necessariamente. Maximizar recompensa acumulada incentiva concentrar observações no melhor braço. Estimar todos os parâmetros com precisão exige distribuir observações entre os braços. A política aleatória estimou melhor todos os λ_a em média, mas teve menor recompensa. O Thompson Sampling maximizou recompensa e estimou muito bem λ_5 , porém coletou poucos dados dos braços subótimos e, por isso, teve maior erro global de estimação.

5. O modelo Poisson é adequado para o exemplo? Quais limitações ele tem?

O modelo Poisson é adequado como ponto de partida porque a recompensa é uma contagem diária de cadastros e λ_a tem interpretação direta como taxa média diária. No entanto, o modelo pressupõe igualdade entre média e variância, independência entre dias, taxa constante ao longo do tempo e exposição comparável entre campanhas. Em aplicações reais, essas hipóteses podem falhar por variação no número de visitantes, sazonalidade, perfil dos usuários, custos, atrasos de conversão, sobredispersão e efeitos de saturação.

6. Que mudanças tornariam o exemplo mais realista?

Possíveis extensões incluem usar modelo Binomial ou Beta-Binomial quando o número de visitantes expostos é conhecido; Poisson com *offset* para visitantes ou impressões; Binomial negativa para sobredispersão; modelos com inflação de zeros; bandits contextuais com perfil, canal, dispositivo e horário; efeitos de calendário e sazonalidade; taxas não estacionárias; custos das campanhas; recompensas atrasadas; e efeitos de saturação ou fadiga por exposições repetidas.

3 Conclusão

As duas partes do trabalho ilustram aspectos complementares de experimentos sequenciais. Na Parte 1, mesmo sob o caso nulo em que todos os braços são iguais, escolher o braço com maior média e depois aplicar um intervalo usual pode reduzir a cobertura. A inferência convencional fica otimista porque ignora o processo de seleção. Na Parte 2, políticas como Thompson Sampling e UCB acumulam mais recompensa ao identificar rapidamente o melhor braço, mas isso não significa que estimem bem todos os parâmetros. Em bandits, há uma diferença importante entre aprender o suficiente para decidir bem e coletar dados de forma equilibrada para estimar todos os efeitos com precisão.